Virtualized Deep Neural Networks for Scalable, Memory-Efficient Neural Network Design

用于可拓展、高效内存的神经网络设计的虚拟化深度神经网络





- 01 作者介绍及文章信息 information about the authors and paper
- 02 研究背景
 background of this thesis

vDNN的三个主要问题
three main questions

04 VDNN++

作者介绍及刊物信息

第一作者



Follow This Author

Shriram S. B. @

Affiliation

Department of Computer Science and Engineering, Indian Institute of Technology, Bombay

Publication Topics

graphics processing units, learning (artificial intelligence), neural nets, storage management



Dynamic Memory Management For Gpu-Based Training Of Deep Neural Networks

Shriram S. B, Anshuj Garg, Purushottam Kulkarni

Deep learning has been widely adopted for different applications of artificial intelligence speech recognition, natural language processing, computer vision etc. The growing size of Deep Neural Networks (DNNs) has compelled the researchers to design memory efficient and performan...

2019 IEEE 33RD INTERNATIONAL PARALLEL AND DISTRIBUTED PROCESSING SYMPOSIUM (IPDPS 2019), pp.200-209, (2019)

引用 28 浏览 8

▶ 下载全文 3 引用 ② 评论 ② 评分

+ 收藏

Shriram S. B.

毕业院校: Department of Computer Science and Engineering, Indian Institute of Technology, Bombay 研究方向: graphics processing units, learning (artificial intelligence), neural nets, storage management

发表刊物

该文章引用数为28,发表在IPDPS上,属于CCFB 类。

IPDPS为IEEE和ACMSIGARCH发起的并行处理国际 会议,每年一次,在CCF会议中排名约为49,专 注于高性能计算领域。

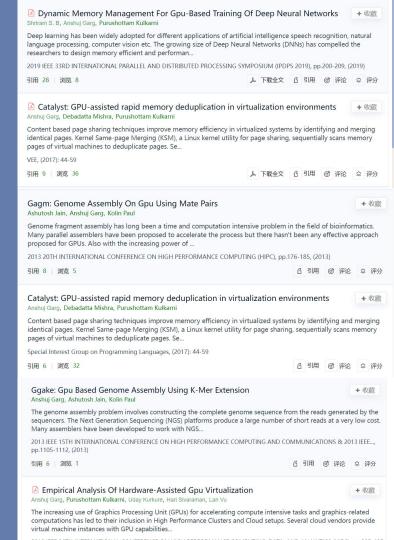
作者介绍及刊物信息 第**二作者**



Anshuj Garg

H-index: 2 论文数: 2 6 引用数: 7

右侧是根据AMiner网站获取的他部分论文数据。

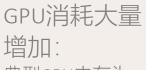




深度神经网络

deep neural network

基于TensorFlow、 PyTorch等框架, 利用GPU并行计 算大量参数矩阵, 通过前向传播和 后向传播达到优 化模型的作用。



典型GPU内存为 **2~24**GB,复杂深 度神经网络需求 在**20**GB以上

提出vDNN:

每次只进行一层参数的计算,计算前将数据预取到GPU,将暂时不用的数据从GPU移到CPU



针对vDNN的三个主要问题, 提出改进后的



vDNN的三个主要缺陷



正逆向传播的停滞

正向传播时, GPU需要等到前一层的数据完全取出后才开始计算; 同理, 反向传播时只有当前一层的数据取回GPU才开始计算。这样对GPU的计算性能会带来很大损失



GPU内存碎片化

由于频繁的对GPU中的数据 进行存入取出操作,导致其 地址碎片化,且新内存池并 不会与旧池合并,导致内存 进一步分散。



CPU的固定内存需求大

CPU内存有限,如果大量分配给GPU,会影响CPU进行原本的工作,还会导致其他进程停滞。



vDNN++

- → 可减少内存碎片化的启发式算法
- **国** 压缩技术减少对固定内存的需要

改进的异步内存传输

Improved Asynchronous Memory Transfer



正逆向传播的停滞

GPU只有当需要用到的前一层 数据完全取出或取回后才进行计 算,降低了运行效率。



异步内存传输

GPU计算与数据取出和取回同步进 行。



正向传播

第n层计算完成后立即计算第n+1层, 让GPU用不到的数据在计算过程中取出 放入CPU内存。



反向传播

如果第m层的计算需要用到第n层的数据,而第n层的数据需要从CPU内存取回至GPU,那么在第m层的计算前就启动第n层的数据的取回工作。



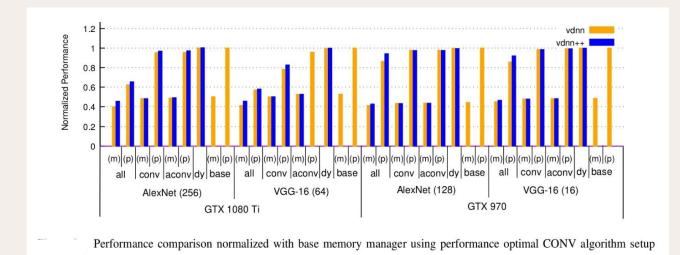
改进的异步内存传输

Improved Asynchronous Memory Transfer

EXPERIMENTS ON VGG-116, VGG-191 ON NVIDIA 1080 TI-EXECUTION TIME OF ONE ITERATION OF TRAINING STEP IN MS

Mode	VGG-	116 (32)	VGG-191 (32)		
	vDNN	vDNN++	vDNN	vDNN++	
dyn	2717	2468	5139	5097	
conv(p)	3055	3018	5139	5097	
all(p)	3170	3129	5244	5209	
aconv(p)	2717	2468	Out of Memory		

看一下改进的性能提升,通过图中对比我们可以 看到vDNN++相较于vDNN确实有一定的提升,经过 作者量化总体性能提大概升了60%。



可减少内存碎片化的启发式算法

Heuristics to Reduce Memory Fragmentation



GPU内存碎片

分配和释放空间的顺序虽然不 影响内存的大小,但是会影响空 间碎片化的数量。



best-fit 启发式算法

用于处理分配请求: 寻找满足请求大小的最小块(该块的内存大小肯定大于请求大小), 然后将该块从小端开始分配。

分配策略

在分配GPU内存时,如果该数据是当前层的输入,就把它们分配在大端地址上,在用完后立即释放该地址,减小碎片化数量。如果不是则采用best-fit启发式算法。

结果:数据分配在预留空间的两端,小端为 暂时不取出的数据,大端为用完后就取出的数据, 中间是空闲区域供分配。



可减少内存碎片化的启发式算法

Heuristics to Reduce Memory Fragmentation

实验中作者只处理了128维的网络,需要最小内存656MB,而改进后作者处理了256维的网络最小内存只需要343MB。可以看到,这里改进提升相当明显。

Table V

Comparison of aggregate peak memory consumed and actual CNMEM pool size required (calculated by pool size calculation algorithm stated in Section IV-B) for best-fit and non-offloaded high end allocation heuristic (high-end).

Network	Mode	aggregate (MB)	prefetch-first best-fit (MB)	derivative-first best-fit (MB)	prefetch-first high-end (MB)	derivative-first high-end (MB)
AlexNet (256)	dyn	1934	2011	2011	1974	1974
	conv(p)	1934	2101	2185	2177	2114
	conv(m)	1184	1452	1476	1427	1465
	all(p)	1783	2126	2050	2037	2020
	all(m)	1100	1375	1361	1570	1362
	aconv(p)	1934	2162	2162	2121	2183
	aconv(m)	1184	1374	1379	1472	1534
VGG- 16(64)	dyn	7243	7243	7243	7439	7439
	conv(p)	7243	7831	7439	8223	7372
	conv(m)	3715	4302	4107	4106	3751
	all(p)	7243	7341	8105	7341	7519
	all(m)	3715	3812	4795	3812	4795
	aconv(p)	7243	8027	7829	7635	7831
	aconv(m)	4010	4155	4073	4302	4106



压缩技术减少对固定内存的需要

Compression technology reduces the demond for fixed memory



CPU的固定内存需求大

CPU内存有限,如果大量分配给GPU,会影响CPU进行原本的工作,还会导致其他进程停滞。



压缩内存

利用ReLU输出层的稀疏特性,在CPU中 完成一个硬件来压缩这些数据,以减少 转移的数据量





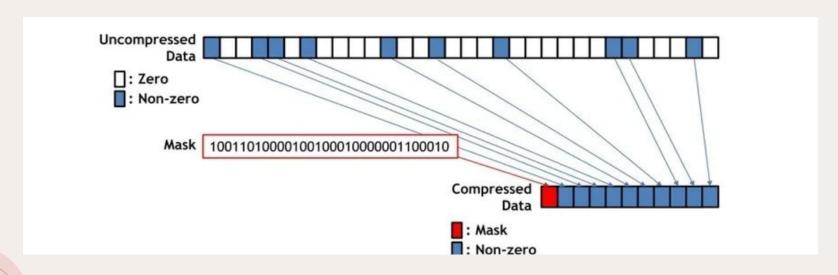
具体思路

在训练过程中,经常检查每层的激活密度(非零元素占比),并选择 低密度的层进行压缩。

压缩技术减少对固定内存的需要

Compression technology reduces the demond for fixed memory

由于硬件是基于模拟器模拟的,压缩算法定制到硬件的形式也比较单一,作者并未深入研究。最后给出的性能提升大约为36%,如下图所示:



vDNN++

- □ 改进的异步内存传输
- 可减少内存碎片化的启发式算法
- □ 压缩技术减少对固定内存的需要

Thank You For Your Leadership And Colleagues

感谢观看

